



INSTITUTO FEDERAL
Rio Grande do Sul

Estatísticas do Tour de France com Apache Cassandra

Mateus Medeiros Schneider
Miguel Bohrz Vogel



Sumário

1. Problema
2. Descrição do sistema
3. Público-alvo
4. Tecnologia escolhida e justificativa
5. Dados que serão armazenados
6. Principais operações
7. Modelo inicial
8. Próximos passos



Problema

- Mais de um século de resultados do Tour de France: 255 mil resultados por etapa.
- Consultas frequentes: ranking de uma etapa, histórico de um ciclista, dados de uma edição.
- Muitos campos existem só para parte das linhas (país, nascimento, equipe, pontos).
- No relacional, isso exige JOINS entre ciclistas, edições, etapas e resultados e muitos NULLs.



Descrição do sistema

Plataforma de consulta de estatísticas do Tour de France:

- cadastro de edições, etapas e ciclistas;
- resultado de cada ciclista em cada etapa (posição, equipe, idade, status);
- consultas: ranking da etapa, etapas da edição e histórico do ciclista;
- agregações: etapas disputadas, vitórias por equipe, idade média.



Público-alvo

- Equipes ciclísticas
- Treinadores
- Jornalistas esportivos
- Plataformas de estatísticas de ciclismo



Tecnologia escolhida

Apache Cassandra, banco NoSQL orientado a colunas



Justificativa da escolha

- Volume: 255 mil resultados (171 mil carregados após validação).
- Acesso previsível por chave: ranking da etapa, histórico do ciclista, etapas da edição, sem JOINS.
- Dados esparsos: pontos vazios em 88% das linhas, equipe em 13%.
- Escalabilidade: partição por etapa e por ciclista; novas edições todo ano.



Dados que serão armazenados

- Ciclista: id, nome, país*, data de nascimento*
- Edição: ano, edicao, data de início, distância, vencedor, equipe vencedora, tempo_total_h, vitorias_etapa, etapas_lideradas
- Etapa: número, data, tipo, distância, origem, destino, vencedor
- Resultado: posição, status, equipe, idade, pontos

(* opcionais)

Fonte (Kaggle): Tour de France — stage_data, tdf_stages, tdf_winners

72 das 104 edições comparáveis com etapas e resultados validados.




Principais operações

- Inserção: edições, etapas, ciclistas e resultados
- Atualização: correção de resultado (ex.: desclassificação) e dados cadastrais
- Remoção: etapa cancelada e seus resultados
- Consulta: edição, etapas da edição, ranking da etapa, histórico do ciclista
- Agregação: etapas por ciclista, idade média, vitórias por equipe



Modelo inicial, MER conceitual



Modelo inicial, entidades e atributos

CICLISTA (ciclista_id, nome, pais, data_nascimento)

EDICAO (ano, edicao, data_inicio, distancia_km, tempo_total_h, vencedor, equipe_vencedora, vitorias_etapa, etapas_lideradas)

ETAPA (etapa_id, ano#, numero, data_etapa, tipo, distancia_km, origem, destino, vencedor)

RESULTADO (resultado_id, ciclista_id#, etapa_id#, posicao_final, status, equipe, idade, pontos)



Prévia do mapeamento para Cassandra

Tabela	PRIMARY KEY	Consulta
<code>ciclistas</code>	<code>ciclista_id</code>	dados cadastrais
<code>etapas</code>	<code>((ano), ordem)</code>	etapas de uma edição
<code>resultados_por_etapa</code>	<code>((ano, ordem), posicao, ciclista_id)</code>	ranking da etapa
<code>resultados_por_ciclista</code>	<code>((ciclista_id), ano, ordem)</code>	histórico do ciclista
<code>edições</code>	<code>ano</code>	dados da edição

ordem = número da etapa na edição



Próximos passos (Trabalho II)

- Carga dos dados reais: 171 mil resultados, 1.431 etapas, 106 edições
- Implementação e demonstração (INSERT, UPDATE, DELETE)
- Consultas: simples, múltiplos critérios, agregação e avançadas (particionamento, replicação, CQL)
- Comparação NoSQL × relacional



Conclusão

- Acesso por chave previsível e volume histórico favorecem o Cassandra.
- A modelagem parte das consultas, com dados duplicados entre tabelas.
- Comparação com o relacional e validação com os dados ficam para o Trabalho II.



Referências

- APACHE SOFTWARE FOUNDATION. Apache Cassandra Documentation. cassandra.apache.org/doc/latest
- KAGGLE. Tour de France (stage_data, tdf_stages, tdf_winners). Disponível em:
<https://www.kaggle.com/datasets/pablomonleon/tour-de-france-historic-stages-data>
- MANICA, E. Material da disciplina IBI-TAB001. IFRS Campus Ibirubá, 2026.





INSTITUTO FEDERAL
Rio Grande do Sul

Fim da apresentação

Obrigado! Espaço para perguntas e dúvidas

